UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO • EPIIS

PREPROCESAMIENTO DE DATASET DE IMÁGENES

Detección y Clasificación Temprana de Patologías Foliares en Papa (*Solanum tuberosum*) mediante Visión Artificial

ASIGNATURA & SEMESTRE
Visión Computacional (IF657BIN)
Semestre 2026-2

DOCENTE RESPONSABLE
CCACYAHUILLCA BEJAR, HANS HARLEY

EXPOSITORES / DESARROLLADORES
• SUPA CUSIPAUCAR, Yeferson (220553)
• VILLAVICENCIO SEGUIL, Edu Piero (220

Cusco - Perú • Octubre 2026

1. CONTEXTO & PROBLEMÁTICA REGIONAL

Patologías Foliares Críticas en el Cultivo de Papa

Impacto fitosanitario y económico en la agricultura altoandina del Cusco

Tizón Temprano (Early Blight)

• Agente: Hongo *Alternaria solani*.
• Patrón visual: Manchas circulares u ovales con **anillos concéntricos distintivos (diana)**.
• Reduce progresivamente el área fotosintética de las hojas inferiores.

Patología Foliar 01

Tizón Tardío (Late Blight)

• Agente: Oomiceto *Phytophthora infestans*.
• Patrón visual: **Lesiones acuosas oscuras** y necrosamiento acelerado bajo humedad alta.
• Históricamente causante de la Gran Hambruna Irlandesa; destruye parcelas en días.

Patología Foliar 02

Follaje Sano (Healthy)

• Hojas libres de necrosis folia
• Presenta variabilidad fenotíp
prominentes, cutícula cerosa y
diversas.
• Clase de referencia para el n

Línea Base de Control

Desarrollado por: Y. Supa & E. Piero Villavicencio

¿Por qué es un Dataset Altamente Desafiante?

Superando las limitaciones de laboratorio con imágenes reales en campo abierto (In-The-Wild)

Retos Fotométricos y Ambientales

- **Iluminación solar cenital no homogénea:** Zonas saturadas por sol directo conviven con sombras proyectadas por hojas superiores.
- **Reflejos especulares:** La cutícula cerosa de la hoja genera puntos ciegos de alto brillo.
- **Fondos no homogéneos:** Tierra, rastrojos, tallos y superposición anatómica foliar complican la segmentación ingenua.

Retos de Reconocimiento Visual

- **Alta Similitud Inter-Clase Temprana:** En fases prematuras, las m
Phytophthora son manchas pardas milimétricas indistinguibles sin
- **Desbalance de escala y perspectiva:** Variabilidad en ángulo cer
cámara móvil.
- **Ruido de sensor:** Gránulo fotométrico en tomas con baja o exce

Desarrollado por: Y. Supa & E. Piero Villavicencio

Pipeline Secuencial de Preprocesamiento

Estructura modular orientada a maximizar la señal patológica foliar

Paso 01

Auditoría de Calidad

Operador Laplaciano bidimensional para cuantificar nitidez y descartar desenfoque.

`Var(∇² I) ≥ 80.0`

Paso 02

Filtrado Bilateral

Denoising no lineal que atenúa ruido fotográfico sin difuminar bordes de manchas.

`d=9, σ_c=75, σ_s=75`

Paso 03

CLAHE en CIE-Lab

Realce adaptativo de contraste local sobre canal L* preservando color clorofílico.

`clip=2.5, grid=8x8`

Paso 04

Letterboxing

Redimensionamiento isotrópico a 256×256 con relleno simétrico; cero distorsión de forma.

`Aspect Ratio 1:1`

Pa

Par

Sep
data

Tra

Desarrollado por: Y. Supa & E. Piero Villavicencio

Auditoría de Calidad y Filtro de Desenfoque

Detección analítica de altas frecuencias mediante el Operador Laplaciano

Fundamentación Matemática

El Laplaciano mide la divergencia del gradiente de intensidad, respondiendo a bordes y transiciones rápidas:

$$\nabla^2 I = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2}, \quad K = \begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$$

Métrica de decisión: **Varianza muestral de la respuesta laplaciana**:

$$\sigma^2(\nabla^2 I) = \frac{1}{MN} \sum_{x,y} (\nabla^2 I(x,y) - \mu)^2$$

Criterio Operativo en Pipeline

✓ **Imagen Nítida:** $\sigma^2 \geq 80.0$
Bordes bien delimitados, conserva micro-texturas foliares.

✗ **Imagen Borrosa / Degradada:** $\sigma^2 < 80.0$
Desenfoque óptico o de movimiento manual; se etiqueta para ex

Garantiza que la red neuronal no aprenda artefactos producidos por

Desarrollado por: Y. Supa & E. Piero Villavicencio

Filtrado Bilateral vs. Filtro Gaussiano

Atenuación de ruido con estricta preservación de los bordes lesionales

Mecánica del Filtro Bilateral

Pondera los píxeles vecinos combinando dos campanas Gaussianas simultáneas:

$$I^{\text{filt}}(p) = \frac{1}{W_p} \sum_q I(q) \cdot \underbrace{G_{\sigma_s}(\|p-q\|)}_{\text{Distancia espacial}} \cdot \underbrace{G_{\sigma_r}(|I(p)-I(q)|)}_{\text{Similitud radiométrica}}$$

• Si $|I(p) - I(q)|$ es grande (borde de la lesión necrótica), el peso fotométrico cae a 0 $\rightarrow$ **¡El borde no se difumina!**

Comparativa de Rendimiento

Filtro Gaussiano Estándar:
Suaviza el ruido pero difumina indiscriminadamente los anillos cor
destruyendo la característica diagnóstica.

Filtro Bilateral Aplicado:
Parámetros óptimos ($d = 9, \sigma_c = 75.0, \sigma_s = 75.0$): Elimina el gra
foliar y mantiene intacta la agudeza del contorno necrosado.

Desarrollado por: Y. Supa & E. Piero Villavicencio

Realce CLAHE en el Espacio Perceptual CIE-Lab

Desacoplamiento ortogonal de luminancia para proteger la firma cromática foliar

¿Por qué en CIE-Lab y no en RGB?

• En **RGB**, los canales de color están íntimamente acoplados a la luz. Modificar contrastes en RGB falsea la tonalidad verde natural de la clorofila.
• En **CIE-Lab**, se desacoplan de forma ortogonal:

```
L*: Luminancia perceptual (0 a 100)
a*: Eje cromático Verde ↔ Rojo
b*: Eje cromático Azul ↔ Amarillo
```

Ecualización Adaptativa Local (CLAHE)

• **Teselas Contextuales (8×8):** El histograma se calcula localmen
realzando micro-detalles en sombras.
• **Límite de Recorte (Clip Limit = 2.5):** Picos de gradiente excesivo
de manera uniforme, evitando la amplificación de ruido de fondo.

Resultado: Micro-lesiones necróticas resaltadas nítidamente sin
sana.

Desarrollado por: Y. Supa & E. Piero Villavicencio

Estandarización Espacial con Letterboxing

Respeto estricto del Aspect Ratio foliar frente al reescalado convencional

El Peligro del Resize Directo Anisotrópico

Al aplicar `cv2.resize(img, (256, 256))` directamente:
• Se comprime o estira la lámina foliar artificialmente.
• Altera la **excentricidad y circularidad** de las lesiones concéntricas de *Alternaria*, engañando a las características morfológicas.
• Induce sesgos morfológicos artificiales en la red convolucional.

Nuestra Solución: Letterboxing Isotrópico

Calcula la escala uniforme conservando el ratio de aspecto W/H

$$s = \min\left(\frac{256}{W_{\text{orig}}}, \frac{256}{H_{\text{orig}}}\right)$$

Centra la imagen reescalada en un lienzo cuadrado 256×256 co
$\Delta x, \Delta y$).

✓ Conserva 100% de la morfología anatómica de la planta.

Desarrollado por: Y. Supa & E. Piero Villavicencio

Particionado Estratificado y Data Augmentation

Prevención de sobreajuste y garantía de evaluación empírica no sesgada

70%

CONJUNTO DE ENTRENAMIENTO (TRAIN)

- Único conjunto con **Data Augmentation**.
- Volteo horizontal (p=0.5).
- Rotación leve ($\pm 15^{\circ}$).
- Micro-ajustes de brillo y contraste.
- Pasa de 21 muestras base a 42 muestras enriquecidas.

15%

CONJUNTO DE VALIDACIÓN (VAL)

- **Cero augmentación sintética.**
- Ajuste de hiperparámetros en tiempo de entrenamiento.
- Refleja estrictamente la variabilidad real en campo abierto.

15%

CONJUNTO DE PRUEBA FINAL

- **Imágenes vírgenes no mani**
- Evaluación final del modelo
- Evita fuga de datos (*data lea*

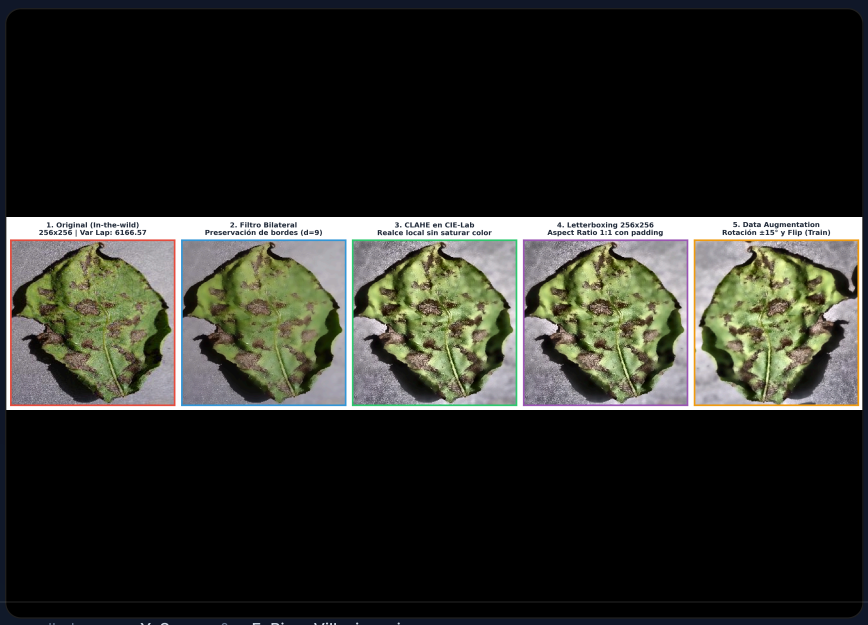
verídicas.

Desarrollado por: Y. Supa & E. Piero Villavicencio

Evidencia Experimental del Pipeline

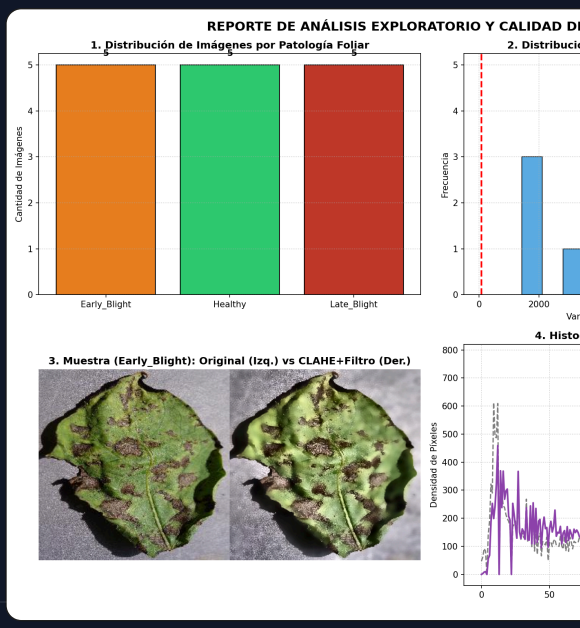
Transformación visual por etapas y reporte del Análisis Exploratorio de Datos (EDA)

Transformación Visual del Pipeline



Paso 1: Raw → Paso 2: Bilateral → Paso 3: CLAHE Lab → Paso 4: Letterbox → Paso 5: Augment

Reporte Diagnóstico EDA (analisis_eda.py)



Distribución balanceada por clase e histograma de nitidez la

Desarrollado por: Y. Supa & E. Piero Villavicencio

Respuestas Metodológicas para la Sustentación

Argumentación técnica ante las interrogantes frecuentes de la cátedra

¿Por qué no ecualización global estándar?

La ecualización global asume una distribución uniforme acumulada en toda la escena. En fotos a cielo abierto, satura las zonas claras del fondo y magnifica drásticamente el ruido en áreas lisas. CLAHE limita la amplificación de contraste en bloques locales de 8×8.

¿Por qué Data Augmentation solo en Train?

Validación y Prueba deben medir el desempeño frente a la realidad pura sin manipular. Aumentar Val/Test generaría sesgo optimista y posible fuga de información (*data leakage*) que invalidaría la rigurosidad científica del experimento.

¿Por qué usar el espacio CIE

El espacio CIE-Lab es percept
la luminancia (L^*) de los comp
Nos permite intensificar las les
matiz natural de la clorofila ve

Desarrollado por: Y. Supa & E. Piero Villavicencio

Conclusiones y Rumbo a la Segunda Entrega

Bases sólidas para la extracción de características y modelado profundo

Logros de la Primera Entrega

✓ **Pipeline Modular y Automatizado:** Código Python limpio y desacoplado (`preprocesamiento.py`, `pipeline.py`, `analisis_eda.py`).
✓ **Preservación Morfológica Estricta:** Letterbox isotrópico a 256×256 y filtrado bilateral sin alteración anatómica foliar.
✓ **Dataset Balanceado y Auditado:** Particionado 70-15-15 con control riguroso de nitidez laplaciana.

Plan para la Segunda Entrega

• **Extracción de Descriptores Clásicos:** Matrices de Coocurrencia descriptores de Haralick y Momentos Invariantes de Hu.
• **Modelado Profundo Convolucional:** Transfer Learning con Mob equilibrio entre precisión diagnóstica y bajo consumo computacio en el campo cusqueño.

¡Muchas gracias por su atención!