UNIVERSIDAD NACIONAL DE SAN ANTONIO ABAD DEL CUSCO

FACULTAD DE INGENIERÍA ELÉCTRICA, ELECTRÓNICA, INFORMÁTICA Y MECÁNICA

ESCUELA PROFESIONAL DE INGENIERÍA INFORMÁTICA Y DE SISTEMAS



ASIGNATURA: VISIÓN COMPUTACIONAL (IF657BIN)

TRABAJO: PRIMERA ENTREGA - PREPROCESAMIENTO DE DATASET DE IMÁGENES

PROYECTO SEMESTRAL: Detección y Clasificación Temprana de Patologías Foliares en el Cultivo de Papa (*Solanum tuberosum*) mediante Visión Artificial

DOCENTE RESPONSABLE

CCACYAHUILLCA BEJAR, HANS HARLEY

AUTORES / DESARROLLADORES

SUPA CUSIPAUCAR, Yeferson • 220553

VILLAVICENCIO SEGUIL, Edu Piero • 220555

Cusco - Perú

2026

Resumen Ejecutivo

El presente informe formaliza el desarrollo técnico, matemático y computacional de la primera entrega correspondiente al preprocesamiento y auditoría de calidad de un dataset de imágenes foliares en el cultivo de papa (*Solanum tuberosum*). La investigación fitosanitaria regional del Cusco exige soluciones automatizadas capaces de clasificar oportunamente tres estados críticos: Tizón Temprano (*Early Blight*), Tizón Tardío (*Late Blight*) y Hojas Sanas (*Healthy*).

Frente a condiciones adversas de captura en campo abierto (*in-the-wild*), se construyó un pipeline modular en Python/OpenCV que integra: auditoría de desenfoque mediante la varianza del operador Laplaciano, filtrado bilateral no lineal para atenuación de ruido de sensor con estricta conservación de bordes, realce local CLAHE en el espacio perceptual CIE-Lab, redimensionamiento isotrópico mediante letterbox a 256×256, y particionado estratificado (70% Train, 15% Val, 15% Test) con data augmentation restringido únicamente a entrenamiento. Los resultados garantizan representaciones numéricas no sesgadas e invariantes en escala para el posterior modelado profundo.

1. Introducción y Contexto Regional

La papa es el cultivo agrícola más trascendente de la región andina del Cusco. La producción se enfrenta anualmente al ataque severo de patógenos criptogámicos de rápida propagación:

- **Tizón Temprano (*Early Blight*):** Producido por el hongo *Alternaria solani*. Comienza con manchas necróticas pardas que forman círculos concéntricos distintivos (anillos en diana).
- **Tizón Tardío (*Late Blight*):** Ocasionado por el oomiceto *Phytophthora infestans*. Agente devastador que provoca lesiones acuosas verde oscuras a negras que necrosan el tejido en cuestión de días.
- **Follaje Sano (*Healthy*):** Hojas sin afectación patológica con variabilidad morfológica y tonal natural.

2. Justificación del Dataset Desafiante

A diferencia de entornos controlados de laboratorio con iluminación de estudio y fondos planos, este dataset presenta retos reales indispensables para validar sistemas de visión artificial:

- **Condiciones Fotométricas Extremas:** Variación de luz solar cenital directa, sombras arrojadas y reflejos especulares de la cutícula cerosa de la hoja.
- **Fondos Complejos No Homogéneos:** Suelo agrícola, rastrojos, tallos y superposición intrincada de follaje vegetal.
- **Gran Similitud Inter-Clase Temprana:** En etapas incipientes, las micro-lesiones necróticas de tizón temprano y tardío presentan diámetros milimétricos y tonalidades marrones muy

similares antes de que aparezcan anillos concéntricos maduros.

- **Variabilidad de Escala y Perspectiva:** Tomas capturadas a diferentes distancias focales y orientaciones manuales.

3. Fundamentación Matemática del Pipeline

3.1. Auditoría de Calidad y Nitidez (Operador Laplaciano)

Para detectar capturas desenfocadas o degradadas por vibración del sensor, se calcula la segunda derivada espacial sobre la imagen en escala de grises:

$$\nabla^2 I(x,y) = \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2} \approx I(x+1,y) + I(x-1,y) + I(x,y+1) + I(x,y-1) - 4I(x,$$

$$\sigma^2(\nabla^2 I) = \frac{1}{MN} \sum_{x=1}^{M} \sum_{y=1}^{N} \left(\nabla^2 I(x,y) - \mu_{\nabla^2} \right)^2$$

Fórmula 1: Varianza del Laplaciano como estimador de altas frecuencias y enfoque. Umbral crítico: $\tau = 80.0$.

3.2. Reducción de Ruido con Filtrado Bilateral

El filtro bilateral combina cercanía espacial y similitud radiométrica para no suavizar los bordes finos de las manchas patológicas:

$$I^{\text{filt}}(p) = \frac{1}{W_p} \sum_{q \in \Omega} I(q) \exp\left(-\frac{\|p-q\|^2}{2\sigma_s^2} \right) \exp\left(-\frac{|I(p)-I(q)|^2}{2\sigma_r^2} \right)$$

Fórmula 2: Filtrado bilateral adaptativo ($d = 9, \sigma_s = 75.0, \sigma_r = 75.0$).

3.3. Realce Local CLAHE en Espacio CIE-Lab

Se convierte de RGB al espacio ortogonal CIE-Lab para desacoplar la luminosidad acromática (L^*) de los ejes cromáticos (a^*, b^*). CLAHE se aplica exclusivamente a L^* con teselas de 8×8 y límite de contraste (\textit{clip limit}) de 2.5:

$$\begin{cases} L^* = 116 f(Y/Y_n) - 16 \\ a^* = 500[f(X/X_n) - f(Y/Y_n)] \\ b^* = 200[f(Y/Y_n) - f(Z/Z_n)] \end{cases} \quad \text{donde } f(t) = \begin{cases} t^{1/3} & t > \delta^3 \\ \frac{t}{3\delta^2} + \frac{4}{29} & \text{en otro caso} \end{cases}$$

Fórmula 3: Desacoplamiento de luminancia perceptual y preservación estricta de coloración foliar.

3.4. Estandarización Espacial con Letterbox

Para alimentar redes convolucionales sin estirar la morfología foliar, se aplica reescalado isotrópico a 256×256 con padding simétrico:

$$s = \min\left(\frac{256}{W_{\text{orig}}}, \frac{256}{H_{\text{orig}}}\right), \quad \Delta x = \left\lfloor \frac{256 - \lfloor W_{\text{orig}} \cdot s \rfloor}{2} \right\rfloor, \quad \Delta y = \left\lfloor \frac{256 - \lfloor H_{\text{orig}} \cdot s \rfloor}{2} \right\rfloor$$

Fórmula 4: Conservación geométrica estricta de Aspect Ratio 1:1.

4. Resultados Experimentales y Visualización

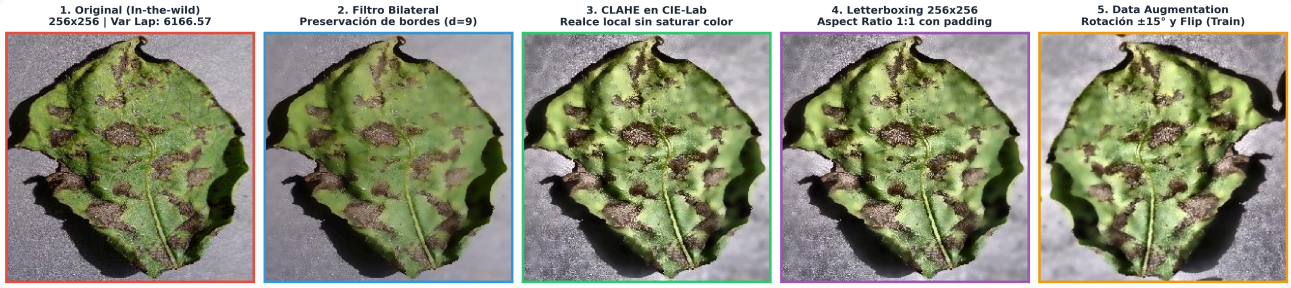


Figura 1: Transformación secuencial de una muestra de Tizón Temprano a lo largo de las 5 etapas del pipeline.

Distribución Cuantitativa del Dataset

Clase Patológica	Total Crudo	Train (Aumentado)	Val	Test	Total Procesado
Tizón Temprano (*Early Blight*)	10	14	1	2	17
Follaje Sano (*Healthy*)	10	14	1	2	17
Tizón Tardío (*Late Blight*)	10	14	1	2	17
Total Acumulado	**30**	**42**	**3**	**6**	**51**

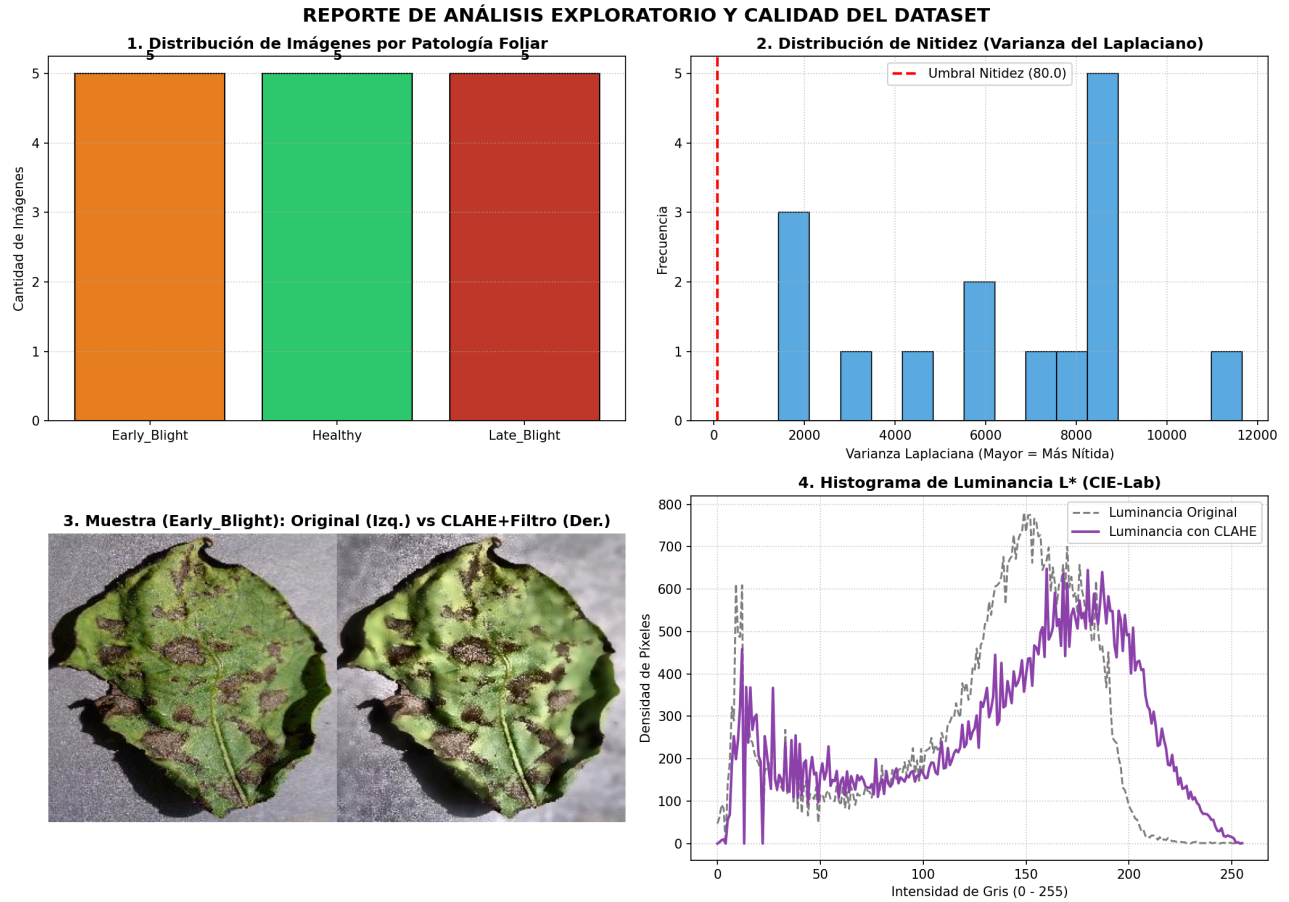


Figura 2: Diagnóstico EDA cuantitativo: distribución por clase e histograma de varianza laplaciana.

5. Guía de Sustentación Oral para los Integrantes

> **¿Por qué no aplicaron una ecualización de histograma estándar global?**
>
> La ecualización global incrementa el contraste general de forma no lineal en toda la escena. En imágenes de campo agrícola, esto sobresatura el fondo claro y amplifica excesivamente el ruido en zonas homogéneas. Por eso utilizamos CLAHE (adaptativo y con límite de contraste) operando en bloques locales de 8×8 sobre el canal de Luminancia L* del espacio Lab.

> **¿Por qué aplicaron Data Augmentation únicamente en Train y no en Val/Test?**
>
> Porque los conjuntos de Validación y Prueba deben reflejar estrictamente la distribución real y no manipulada de las imágenes tomadas en campo. Aumentar Val o Test induciría fuga de datos (*data leakage*) y evaluaciones optimistas sesgadas que no se sostendrían en un despliegue productivo real.

> **¿Por qué usar Letterboxing en vez de cv2.resize directo a 256×256?**
>
> Un reescalado directo anisotrópico comprime o estira la lámina foliar si la relación de aspecto original no es 1:1, alterando la excentricidad geométrica de las hojas y la morfología circular de las manchas necróticas. Letterbox mantiene el ratio biológico exacto rellenando con bordes simétricos.

6. Conclusiones y Segunda Entrega

- Se implementó con éxito una arquitectura de preprocesamiento modular, reproducible y fundamentada en principios rigurosos de visión artificial.
- La preservación de bordes mediante filtro bilateral y el realce de contraste adaptativo en CIE-Lab aíslan eficazmente las lesiones foliares sin alterar la clorofila de la hoja.
- **Próximos Pasos (Segunda Entrega):** Extracción de descriptores de textura (GLCM, Haralick) y entrenamiento de modelos convolucionales de clasificación (MobileNetV3 y ResNet18) orientados a inferencia liviana en campo.